ПолярТех
Ассистент сервисной службы на Graph RAG

Финальный проект курса «ИИ-мышление: Наука и технологии»

Участник: Крохин Роман Олегович. Индивидуальный проект.
Дата: 10 ноября 2026.
Версия сдачи: v1.0.

Открытый репозиторий:
https://github.com/RomanKrohin/itmo-polyartech-graphrag-2026

1. Задача

Диспетчеру нужно превратить сообщение о модели холодильного оборудования и коде ошибки в обоснованный выбор актуальной детали. Руководство описывает исходную комплектацию, бюллетень сообщает замену, а актуальные цена и остаток находятся только в ERP. Ошибка на любом переходе может привести к повторному поиску, отклонённому заказу и увеличению простоя оборудования.

Цель системы - связать факты нескольких документов, ответить на обзорные вопросы по всему корпусу и обратиться к ERP, сохранив подтверждение заказа за человеком. Корпус и ERP учебные. Приведённые в исходной постановке 12 минут поиска и один ошибочный заказ из двенадцати не измерялись в этом проекте.

Полный корпус: **80 документов, 92 чанка**. Сравнение выполнено на всех 24 открытых вопросах из questions_dev.jsonl; скрытые вопросы недоступны и в приведённые результаты не входят.

Конкретный сбой baseline: на вопрос «Какую деталь заказать при ошибке E-17 на AR-210?» плоский поиск ответил P-1042. Он вернул три руководства без сервисного бюллетеня SB-2025-03 и пропустил замену снятой детали на P-1042B.

2. Решение

Этап	Реализация и причина выбора
Извлечение	LLMClient + EXTRACTION_SCHEMA, явные направления восьми типов связей, пример и закрытый словарь. Одна повторная попытка при сломанном JSON или неверной сигнатуре. Коды проверяются по тексту. Однозначные маркированные строки «код - отказ узла» дополняются кодом при единственном коде и одном узле из словаря; FAILED из руководств отклоняется.
Граф	NetworkX DiGraph. Канонические ID, источники на узлах и рёбрах, вес по уникальным чанкам. Встречные замены разрешаются по весу; равный конфликт удаляет обе связи.
Сообщества	Взвешенный Louvain с seed=7. Количество отказов считает код; каждое ребро принадлежит сообществу своего источника, поэтому межсообщественные связи не теряются и не дублируются. LLM формулирует сводку до 150 слов.
Поиск	Local: опорные сущности без LLM, пути до трёх связей и цепочки замен; одна опора - окрестность глубины два. Global: оценка каждой сводки и объединение полезных частичных ответов.
Агент	Пять инструментов, проверка аргументов и происхождения part_id, кеш повторов, до трёх попыток ERP, лимит вызовов и остановка перед заказом.

3. Результаты

Модель генерации: qwen3:4b-instruct-2507-q4_K_M.
Эмбеддинги: bge-m3 (1024 измерения). Ollama на Apple M4, температура 0, seed=7. Проверка проводилась нативно через Python 3.12; Docker Compose в этой среде не запускался. Инфраструктурные файлы шаблона не изменялись.

Режим	Local 5	Multihop 7	Global 4	Tool 5	Refusal 3	Всего 24
baseline	100.0%	57.1%	0.0%	0.0%	100.0%	50.0%
local	40.0%	42.9%	0.0%	0.0%	100.0%	33.3%
global	60.0%	28.6%	50.0%	0.0%	66.7%	37.5%
agent	40.0%	42.9%	75.0%	80.0%	100.0%	62.5%

Режим	Recall источников	Ответы с выдуманными фактами	Вызовы LLM на вопрос	Токены на вопрос
baseline	85.6%	0.0%	1.000	1359.042
local	93.8%	4.2%	0.875	707.375
global	72.2%	0.0%	11.708	4036.833
agent	75.0%	0.0%	5.250	4082.750

Токены - сумма входных и выходных токенов, а не денежная стоимость. Повторный запрос из дискового кеша учитывается как логический вызов с исходным количеством токенов, поэтому стоимость режимов сопоставима. Эмбеддинги кешируются отдельно.

Корректность считается штатным оценщиком: ключевые факты, нужные вызовы ERP и корректный отказ/подтверждение. «Выдуманные факты» здесь означают неизвестные коды и неподтверждённые цены/остатки. Известный, но неверно применённый код или ошибочная причинная связь могут не попасть в эту метрику. Recall источников оценивает покрытие заданных групп документов и не проверяет каждое предложение ответа.

На dev-21 local оценщик пометил «2 шт» как выдуманный факт, хотя количество 2 было задано пользователем. Это ложное срабатывание проверки чисел в данном примере; опубликованное значение fabricated_rate сохранено без исправления. Local не создавал заказ и не обращался к ERP.

На dev-13 agent штатный оценщик засчитал ответ «Недостаточно информации...» как верный: в тексте упомянуто «пусковое реле». По смыслу частота отказов так и не определена. Поэтому accuracy отражает работу штатного проверяющего по ключевым фактам и не гарантирует смысловую корректность каждого засчитанного ответа.

Извлечение и индекс

Объект	Precision	Recall	Найдено / эталон
Сущности	88.7%	97.6%	186 / 165
Связи	100.0%	85.1%	137 / 161

Эталон: 16 документов. В полном графе **112 узлов и 250 рёбер**, сообществ 11, встречных конфликтов REPLACED_BY 0. Проверками отброшено 126 сущностей и связей суммарно; из них недопустимых связей 115.

Логическая стоимость индексации: 167 вызовов LLM, 188137 входных и 64662 выходных токенов. Кеш подготовлен настоящими вызовами той же модели; FakeLLM используется только в контрактных тестах.

4. Где граф помогает и где уступает

Граф находит замену детали: dev-06

Вопрос: Какую деталь заказать при ошибке E-17 на AR-210?

Режим	Фактический ответ / фрагмент
baseline	При ошибке E-17 на AR-210 необходимо заказать деталь P-1042 - пусковое реле.
local	1. Ошибка E-17 указывает на пусковое реле. 2. AR-210 неисправен из-за пускового реле. 3. AR-210 имеет деталь P-1042. 4. P-1042 заменён на P-1042B. Последняя актуальная деталь - P-1042B. Ответ: P-1042B.

Baseline извлёк три руководства без бюллетеня SB-2025-03 и предложил снятую с производства P-1042. В local путь E-17 - INDICATES - пусковое реле - IS_A - P-1042 - HAS_PART - AR-210 связывает ошибку с комплектацией. Затем добавляется REPLACED_BY до P-1042B. Получен правильный актуальный номер; бюллетень присутствует в источниках.

Потерянная связь с регламентом: dev-01

Вопрос: По какому регламенту устраняют ошибку E-17?

Режим	Фактический ответ / фрагмент
baseline	По регламенту SP-104 устраняют ошибку E-17.
local	Ответ: по регламенту замены детали P-1042 на P-1042B.

Baseline нашёл регламент SP-104 и ответил верно. Извлечение не создало ребро E-17 - FIXED_BY - SP-104, поэтому SP-104 остался изолированным узлом. Local видит детали и замену, но не нужный регламент; генерация подменяет номер регламента описанием ремонта. Доказуемая цепочка в графе полезна только при достаточной полноте извлечения.

5. Ошибки системы

1. Извлечение: пропущенный FIXED_BY

В procedure_SP-104.md описано устранение E-17 по SP-104, но обязательная связь не извлечена. Узел SP-104 изолирован. Последующий поиск не может восстановить отсутствующее ребро: на dev-01 не назван правильный номер регламента.

Вопрос: По какому регламенту устраняют ошибку E-17?

2. Генерация local: бессодержательный ответ

На dev-02 граф содержит факт E-22 - INDICATES - циркуляционный насос, однако модель выдала строку «1». Факт найден, но ответ не сформулирован. Проверка известных кодов и чисел не обнаруживает такую смысловую ошибку.

Вопрос: На отказ какого узла указывает ошибка E-22?

Наблюдение: 1

3. Сводка сообщества: неверное приписывание числа

Код посчитал для сообщества Арктики 9 отказов пускового реле, 4 отказа датчика температуры и 1 отказ контроллера: всего 14. Сводка сначала правильно указывает 9 отказов реле, затем пишет «пусковое реле (всего 14)». Готовые подсчёты переданы верно, но модель перенесла сумму на один узел. Такая ошибка может исказить global, хотя не содержит неизвестных кодов и может не учитываться fabricated_rate.

6. Границы системы и контроль действий

Реальный прогон dev-17: search_knowledge нашёл P-1042B, затем check_stock вернул 3 штуки в Казани, а get_price - 2630 рублей. На dev-21 агент вернул «Подтвердите заказ: 2 шт. P-2054C, склад Москва, модель BZ-120» и остановился перед созданием заказа. Шаги сохранены в eval_agent.json.

Создание заказа - единственный инструмент с изменением состояния ERP. По умолчанию confirm=False: при попытке заказа агент возвращает needs_confirmation=True и pending_action с конкретными part_id, warehouse, qty и model; ERP при этом не вызывается. При confirm=True заказ разрешён только с явно указанным пользователем количеством. Одинаковый повторный вызов получает сохранённый результат, что предотвращает дублирование заказа в одном диалоге.

Перед любым ERP-вызовом проверяются схема аргументов, склад, формат номера детали и количество. Деталь должна быть названа в вопросе либо получена в предыдущих результатах. ErpNotFound, нулевой остаток и ErpUnavailable сохраняют разный смысл; при недоступности выполняются две повторные попытки. На итоговом ответе проверяются коды, цены и остатки; одна попытка исправления неподтверждённого ответа, затем отказ. Эти проверки ограничивают ошибки модели, но не являются доказательством истинности любого текста из инструментов.

Лимиты: до 6 вызовов инструментов; факты local ограничены 8000 символами, пути - тремя связями. Словарь закрыт: новые узлы и поставщики требуют обновления данных. Направление ошибочно извлечённой, но типологически допустимой связи автоматически не доказывается. Сводка может потерять факт, а строковый оценщик - не заметить смысловую ошибку.

7. Следующий шаг

Возвращать сводку в структурированном формате: отдельные component_id, product_line и count, сверять каждое число с Counter исходного графа, затем формировать текст из проверенных полей. Проверка идеи: на том же индексе число несовпадений счётчиков должно снизиться до нуля; повторить четыре global-вопроса и сравнить accuracy и стоимость с текущим прогоном.

8. Вклад участника

Крохин Роман Олегович - единственный участник и владелец репозитория. Область работы: шесть модулей extraction, graph_builder, communities, search, tools и agent; интеграционные прогоны, сохранение артефактов и подготовка отчёта. Разработка и выполнение проверок проводились с помощью ИИ-ассистента, как раскрыто ниже. Исходная инфраструктура, тесты и учебные данные предоставлены авторами курса.

9. Использование ИИ-инструментов

Использован ChatGPT / Codex для чтения требований, генерации и исправления кода, настройки локального запуска, выполнения тестов и оценки, анализа ошибок и подготовки текста/вёрстки отчёта. Код проверен штатными тестами и линтером; численные результаты взяты из сохранённых JSON-прогонов, а не придуманы моделью. Работа не заявляется как написанная без ИИ. Для защиты автору необходимо самостоятельно понять реализацию и проверить объяснения.

Проверка: 142 штатных теста проходят, ruff check проходит. Результаты четырёх режимов, оценка извлечения, граф, сводки, статистика индексации и кеш сохранены в artifacts/. Репозиторий снабжён меткой v1.0. Данные скрытой проверки и результаты Docker-запуска не заявляются.